

Resumen: Ridge Regression y Lasso

Apuntes de Regularización y Modelos Lineales

Introducción a los Problemas de Mínimos Cuadrados

El enfoque tradicional de Mínimos Cuadrados Ordinarios (*Ordinary Least Squares*) presenta desventajas significativas, especialmente en entornos de alta dimensionalidad. Cuando el número de predictores es mayor que el número de observaciones ($d > n$), el modelo sufre de una alta varianza y la matriz de diseño de las observaciones no es invertible, lo que impide encontrar una solución única y estable.

Para solucionar esto, se introducen técnicas de **regularización**, las cuales imponen restricciones al modelo para reducir la varianza a costa de introducir un pequeño sesgo, mejorando así la capacidad de predicción del modelo con datos nuevos.

Regresión Ridge (Penalización L_2)

La regresión Ridge soluciona el problema de inestabilidad añadiendo un término de penalización a la función de pérdida. Esta penalización está basada en la suma de los cuadrados de los coeficientes (norma L_2).

- **Efecto:** Este método reduce de manera proporcional el tamaño de los coeficientes hacia cero (aunque nunca llegan a ser exactamente cero).
- **Ventaja:** Ofrece una gran protección contra la alta varianza y asegura que la matriz sea invertible, permitiendo obtener una solución analítica cerrada.

Lasso (Penalización L_1)

El método Lasso (*Least Absolute Shrinkage and Selection Operator*) aplica una penalización basada en la suma de los valores absolutos de los coeficientes (norma L_1).

- **Efecto y Ventaja Principal:** A diferencia de Ridge, Lasso tiene la capacidad de forzar a que algunos coeficientes se vuelvan **exactamente cero**.
- **Selección de Variables:** Al anular coeficientes, Lasso realiza una selección automática de variables, produciendo modelos más simples, interpretables y dispersos (*sparse*).

Interpretación Geométrica

La diferencia en el comportamiento de ambos métodos se puede entender a través de su geometría cuando se visualizan las curvas de error frente a las regiones de restricción (o "presupuesto" del modelo):

- **Lasso (L_1):** La región de restricción tiene forma de **rombo** (o polítopo con esquinas pronunciadas). Las curvas de error tienden a intersectar esta región directamente en las esquinas (los ejes), lo que provoca que el valor de esa variable se vuelva cero.
- **Ridge (L_2):** La región de restricción tiene forma de **círculo** (o hiperesfera). Al no tener esquinas, la intersección rara vez ocurre sobre los ejes, por lo que los coeficientes se reducen, pero no se anulan.

Algoritmos de Optimización

Debido a la naturaleza de la penalización del valor absoluto, Lasso no siempre tiene una solución explícita o analítica, por lo que se requieren métodos numéricos para calcular sus estimadores:

- **Algoritmo LARS** (*Least Angle Regression*): Un método eficiente para ajustar modelos de regresión con penalización L_1 .
- **Descenso de Coordenadas** (*Coordinate Descent Algorithm*): Un algoritmo muy utilizado que optimiza el modelo actualizando un parámetro (o coordenada) a la vez mientras mantiene el resto fijo. Es computacionalmente rápido y adecuado para Lasso.

Elastic Net

El método *Elastic Net* surge como una generalización que combina simultáneamente las penalizaciones L_1 (Lasso) y L_2 (Ridge).

- **Beneficios:** Logra retener la valiosa propiedad de selección de variables de Lasso (coeficientes en cero) y hereda la estabilidad de Ridge.
- **Correlación:** Es particularmente útil cuando existen grupos de variables predictoras que están altamente correlacionadas entre sí, ya que tiende a seleccionarlas o descartarlas en grupo.